Projet Data Engineering on Cloud

Mastère Data Engineering & AI

Latifa KOUHAFA

Imane KADI

Encadré par :

Alex andre Bergère

Table des matières

Introduction 4

Présentation du projet 4

Données Utilisées 5

Description des sources de données 5

Types de données et leur format 5

Architecture du Système 7

Schéma général de l'architecture 7

Groupe de ressources Azure : *GPResource-cloud* 8

Traitements effectués 8

ADF : Collecte et ingestion 8

ADLS : Stockage 10

Databricks : Transformation 12

Synapse Analytics : Modélisation 16

PowerBI : Visualisation 19

Introduction

Présentation du projet

Dans le cadre de la validation du bloc de compétence 3 : Implémenter et optimiser des solutions de stockage et de traitement de données sur le cloud, nous avons entrepris un projet de Data Engineering en utilisant des services cloud. Ce projet vise à démontrer notre capacité à collecter, stocker, traiter et analyser des données en utilisant une infrastructure cloud distribuée.

Pour ce projet, nous avons choisi d'explorer les données relatives à la pandémie de COVID-19. Nous avons principalement utilisé des données disponibles sur GitHub, notamment le repository de Sayantan Barat, qui contient des informations détaillées sur les victimes et les cas infectés par le COVID-19.

Pour la mise en œuvre de ce projet, nous avons utilisé les services cloud de Microsoft Azure, qui offrent une gamme complète d'outils et de services pour le stockage, le traitement et l'analyse des données :

- **Azure Data Factory** : Cet outil d'intégration de données nous a permis d'automatiser le processus de collecte de données à partir des différentes sources, de les déplacer et de les transformer. Azure Data Factory a joué un rôle crucial dans l'orchestration des workflows de données et l'ingestion des données brutes dans notre système.
- **Azure Data Lake Storage Gen2** : Nous avons utilisé ce service pour stocker les données brutes et transformées. Azure Data Lake Storage Gen2 offre une solution de stockage scalable et sécurisée, adaptée pour gérer de grandes quantités de données.
- **Azure Databricks** : Pour le traitement et la transformation des données, nous avons tiré parti d'Azure Databricks. Cet environnement d'analyse collaboratif, basé sur Apache Spark, nous a permis d'effectuer des transformations complexes et des analyses avancées sur les données ingérées.
- **Azure Synapse Analytics** : Nous avons utilisé Azure Synapse Analytics pour la gestion de notre Data Warehouse. Ce service intégré nous a permis de combiner le Big Data et les analyses de données dans un seul environnement, facilitant ainsi le traitement des requêtes analytiques à grande échelle et l'optimisation des performances.
- **Power BI** : Pour la visualisation des données et la création de rapports interactifs, nous avons utilisé Power BI. Cet outil nous a permis de transformer les données traitées en insights visuels.

Données Utilisées

Description des sources de données

Pour ce projet, nous avons collecté des données sur la pandémie de COVID-19 provenant de différentes sources. Les sources de données utilisées sont les suivantes :

1. **Cause_deces_uk.csv**
   - Contient des informations sur les cas confirmés et les décès au Royaume-Uni et en Inde.
2. **reponse_pays.csv**
   - Recense les mesures mises en place par différents pays pour lutter contre la pandémie.
3. **hopital_admissions.csv**
   - Données sur les admissions des hôpitaux liées au COVID-19.
4. **test.csv**
   - Informations sur les tests de dépistage du COVID-19 réalisés par pays.
5. **Cause_deces.csv**
   - Données globales sur les cas confirmés et les décès dus au COVID-19.

Types de données et leur format

Les données collectées couvrent différents aspects de la pandémie de COVID-19 et sont au format CSV. Voici un résumé des types de données et de leur format :

1. **Cause_deces_uk.csv :**
   - **Type de données** : Cas confirmés et décès.
   - **Format** : CSV
   - **Colonnes** :
     - country : Nom du pays
     - country_code : Code ISO du pays
     - continent : Continent du pays
     - population : Population du pays
     - indicator : Type de donnée (cas confirmés ou décès)
     - daily_count : Nombre quotidien de cas ou de décès
     - date : Date de l'observation
     - rate_14_day : Taux sur 14 jours
     - source : Source des données

2. **Reponse_pays.csv** :
    - **Type de données** : Mesures mises en place par les pays
    - **Format** : CSV
    - **Colonnes** :
        - Country : Nom du pays
        - Response_measure : Mesure de réponse mise en place
        - change : Changement apporté par la mesure
        - date_start : Date de début de la mesure
        - date_end : Date de fin de la mesure

3. **hopital_admissions.csv** :
    - **Type de données** : Admissions à l'hôpital
    - **Format** : CSV
    - **Colonnes** :
        - country : Nom du pays
        - indicator : Indicateur de l'admission
        - date : Date de l'observation
        - year_week : Semaine de l'année
        - value : Valeur de l'indicateur
        - source : Source des données
        - url : URL de la source

4. **test.csv** :
    - **Type de données** : Tests de dépistage
    - **Format** : CSV
    - **Colonnes** :
        - country : Nom du pays
        - country_code : Code ISO du pays
        - year_week : Semaine de l'année
        - new_cases : Nombre de nouveaux cas

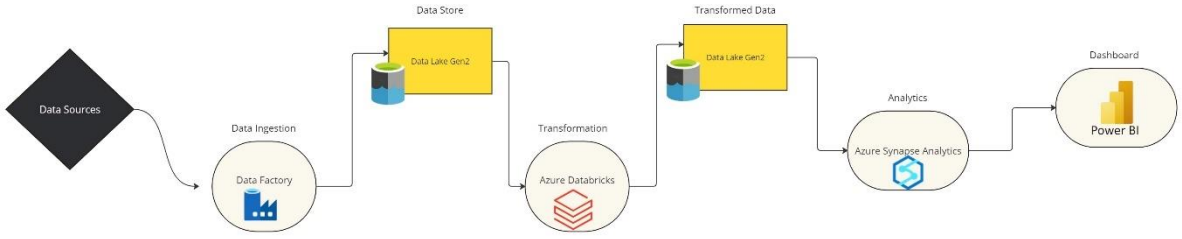
- tests_done : Nombre de tests effectués
- population : Population du pays
- testing_rate : Taux de tests
- positivity_rate : Taux de positivité
- testing_data_source : Source des données de tests

5. **cause_deces.csv** :
    - **Type de données** : Cas confirmés et décès
    - **Format** : CSV
    - **Colonnes** :
        - country : Nom du pays
        - country_code : Code ISO du pays
        - continent : Continent du pays
        - population : Population du pays
        - indicator : Type de donnée (cas confirmés ou décès)
        - daily_count : Nombre quotidien de cas ou de décès
        - date : Date de l'observation
        - rate_14_day : Taux sur 14 jours
        - source : Source des données

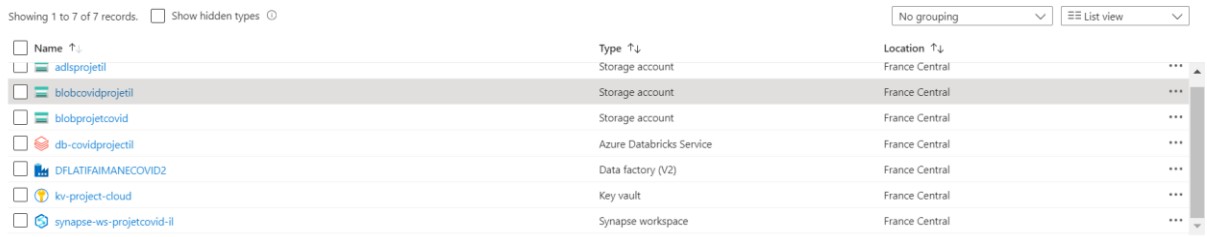
En utilisant ces différentes sources de données, nous avons pu analyser l'impact de la pandémie sous différents angles et de développer des visualisations pertinentes.

Architecture du Système

Schéma général de l'architecture



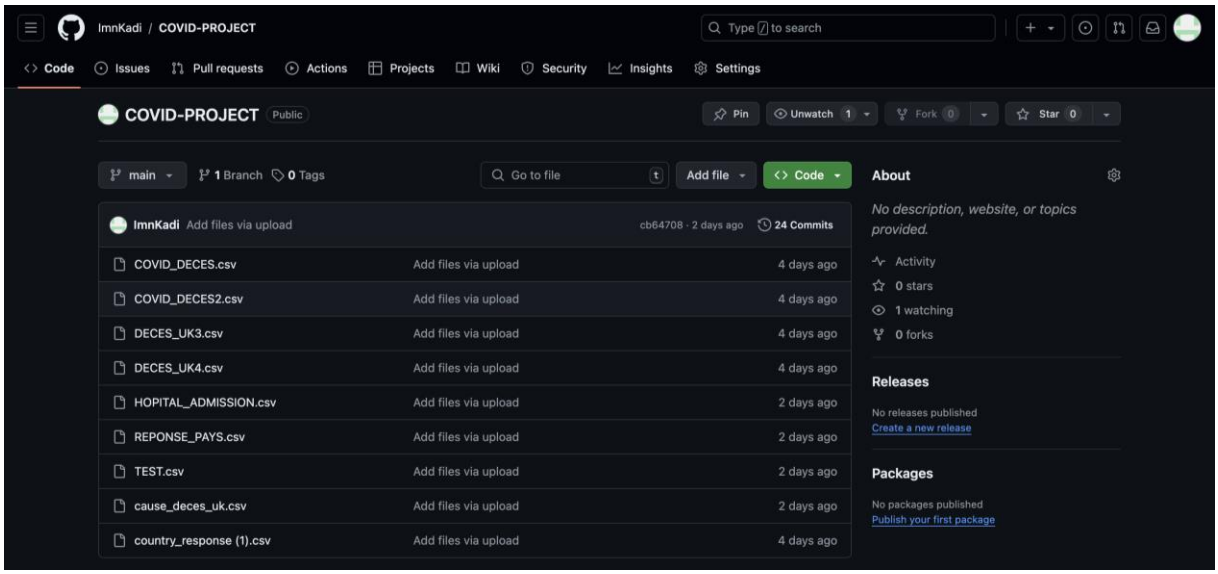
Groupe de ressources Azure : *GPResource-cloud*



Traitements effectués

ADF : Collecte et ingestion

Récupération des fichiers CSV depuis GitHub



1. Création d'une pipeline de copie dans ADF

La tâche principale consiste à copier les fichiers. Voici les étapes détaillées de cette configuration :

a. Configuration du service lié (Linked Service)

1. Source HTTP (GitHub)
    - Nous avons configuré un service lié pour accéder aux fichiers CSV hébergés sur GitHub. Ce service utilise le protocole HTTP pour se connecter aux URLs des fichiers CSV.
    - Dans la section *Linked Services* d'ADF, nous avons créé un nouveau service lié en sélectionnant "HTTP" comme type de connexion.
    - Nous avons fourni l'URL de base de GitHub et configuré les paramètres nécessaires pour accéder aux fichiers CSV.

2. Sink (Azure Data Lake Storage Gen2)
    - Nous avons configuré ADLS Gen2 lié pour notre stockage cible.
    - Dans la section *Linked Services*, nous avons créé un nouveau service lié en sélectionnant "Azure Data Lake Storage Gen2" comme type de connexion.
    - Nous avons fourni les informations nécessaires pour se connecter à notre compte ADLS Gen2, telles que l'URL du compte de stockage et les informations d'authentification.

b. Création de la pipeline de copie

1. Activité de copie (Copy Activity)
    - Nous avons ajouté une activité de copie à notre pipeline pour transférer les fichiers CSV de GitHub vers ADLS Gen2.
2. Configuration de la source
    - Dans les paramètres de la source, nous avons défini le type de fichier comme "DelimitedText" (texte délimité) pour les fichiers CSV.
    - Nous avons spécifié le chemin d'accès complet aux fichiers CSV sur GitHub, incluant le nom du fichier.
3. Configuration de la destination (Sink)

- Nous avons configuré la destination de l'activité de copie pour écrire les fichiers CSV dans ADLS Gen2.
- Dans les paramètres de la destination, nous avons spécifié le service lié ADLS Gen2 et défini le chemin où les fichiers CSV seront stockés dans le Data Lake.
- Nous avons choisi le format de fichier "DelimitedText" pour maintenir les données au format CSV.

4. Exécution et validation
    - Après avoir configuré la source et la destination, nous avons exécuté la pipeline de copie pour transférer les fichiers CSV de GitHub vers ADLS Gen2.



Figure 1- Pipeline de copie

Pipeline name	Run start	Run end	Duration	Status	Triggered by	Run ID	Parameters
data-ingestion	7/19/2024, 5:14:04 PM	7/19/2024, 5:15:13 PM	1m 10s	Succeeded	Manual trigger	73b79857-9f67-497a-	
data-ingestion	7/19/2024, 5:12:24 PM	7/19/2024, 5:12:56 PM	32s	Succeeded	Manual trigger	9d41ec19-df31-4169-	
data-ingestion	7/19/2024, 5:05:42 PM	7/19/2024, 5:06:20 PM	39s	Succeeded	Manual trigger	6c569458-70f7-4521-	
data-ingestion	7/19/2024, 4:49:11 PM	7/19/2024, 4:49:52 PM	41s	Succeeded	Manual trigger	140bf9bb-b64a-4186-	
data-ingestion	7/19/2024, 4:47:00 PM	7/19/2024, 4:47:33 PM	33s	Succeeded	Manual trigger	3146e846-5081-45dc-	
data-ingestion	7/19/2024, 4:46:26 PM	7/19/2024, 4:46:43 PM	18s	Succeeded	Manual trigger	adfcbd73-d432-43d9-	
data-ingestion	7/19/2024, 4:43:44 PM	7/19/2024, 4:44:01 PM	17s	Succeeded	Manual trigger	235ded32-e38a-4cd9-	

Figure 2- Succès de l'activité de copie

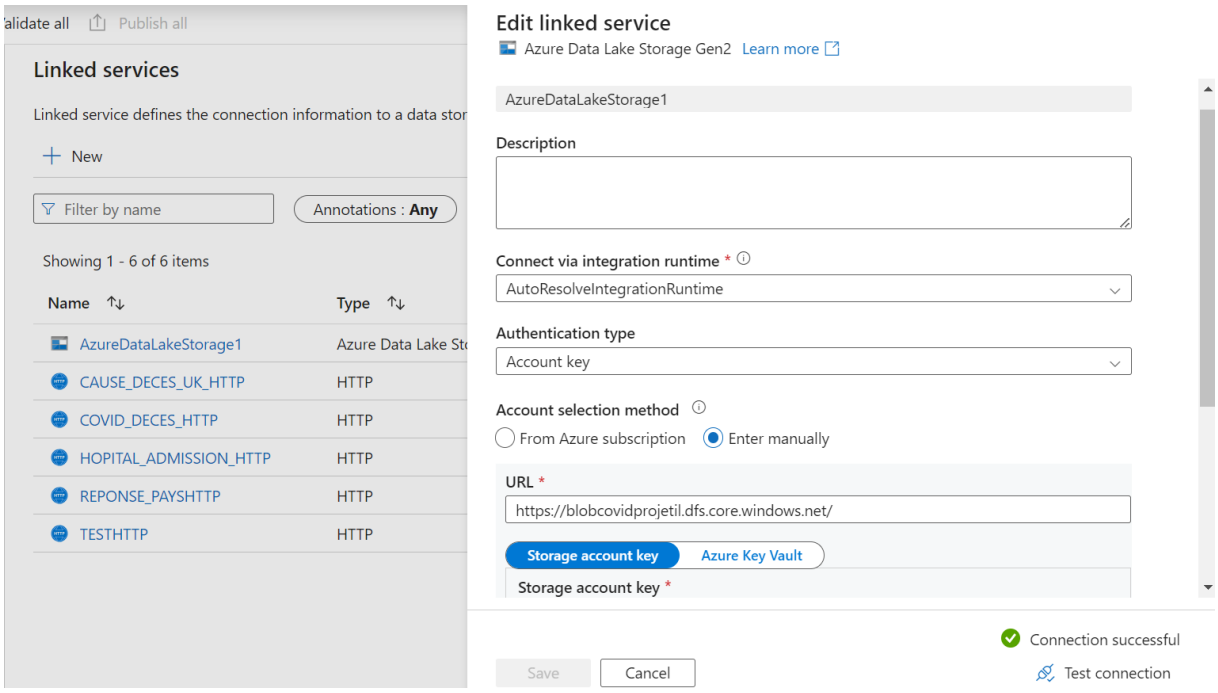


Figure 3- Configuration du service lié de destination ADLS Gen2

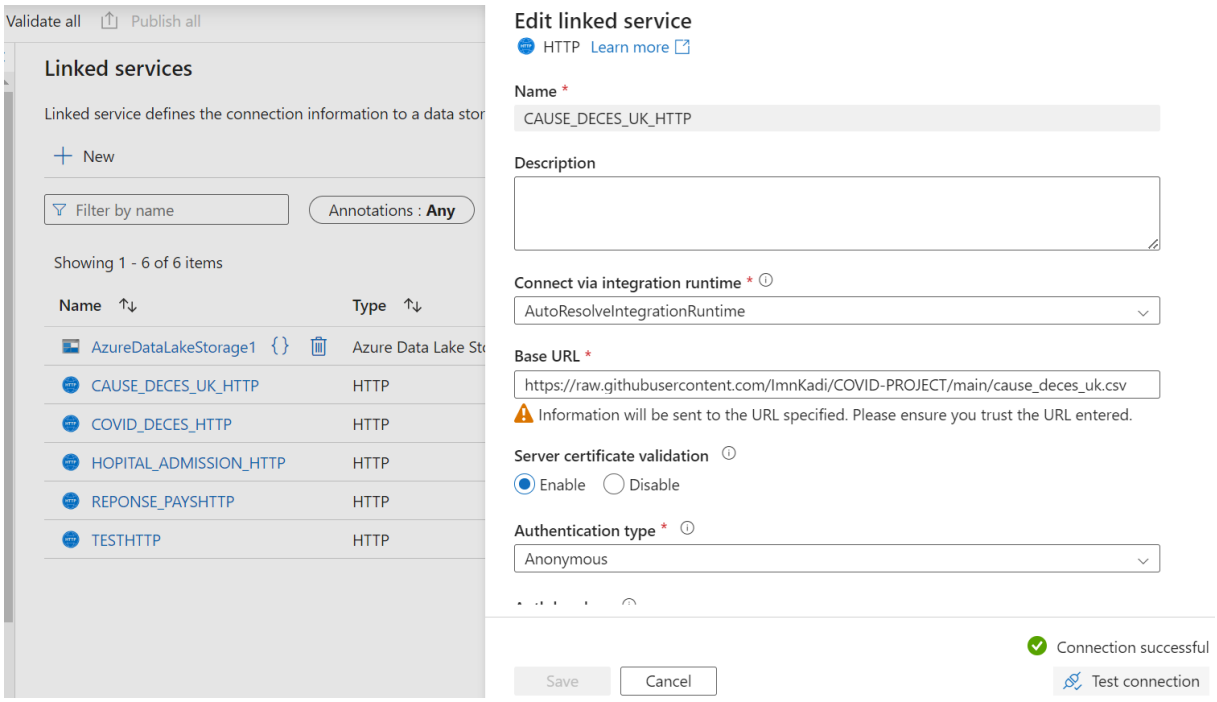
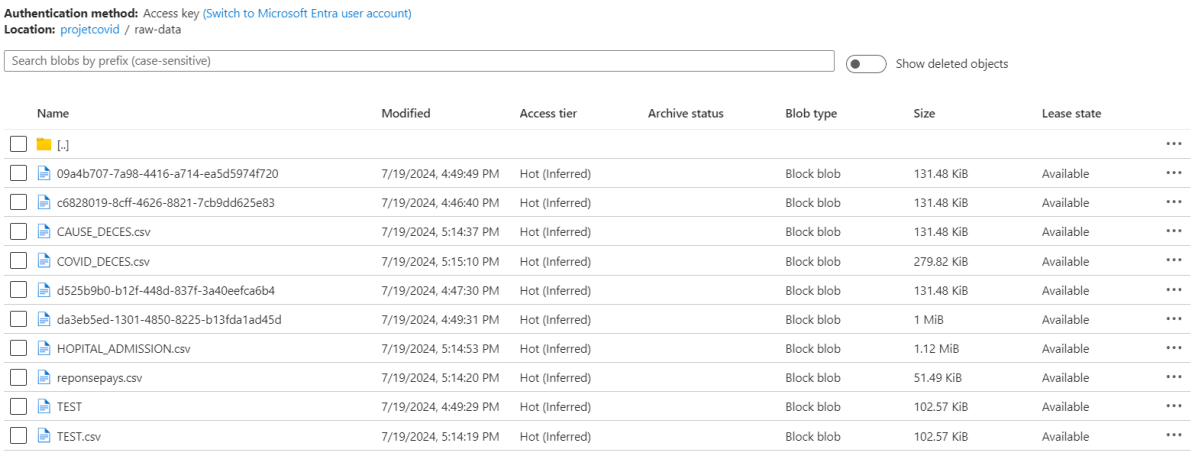


Figure 4- Configuration du service lié Source HTTP

ADLS : Stockage

Nous avons validé le succès de l'ingestion en vérifiant que les fichiers CSV sont bien présents dans le conteneur *raw-data* d'ADLS et que les données sont complètes et correctement formatées.

On stocke les données brutes, telles qu'elles sont ingérées, afin de préserver leur état original pour des transformations et analyses ultérieures tout en assurant une organisation structurée et sécurisée des données.



Authentication method: Access key (Switch to Microsoft Entra user account)
Location: projetcovid / raw-data

Search blobs by prefix (case-sensitive) — Show deleted objects

Name	Modified	Access tier	Archive status	Blob type	Size	Lease state
[..]						
09a4b707-7a98-4416-a714-ea5d5974f720	7/19/2024, 4:49:49 PM	Hot (Inferred)		Block blob	131.48 KiB	Available
c6828019-8cff-4626-8821-7cb9dd625e83	7/19/2024, 4:46:40 PM	Hot (Inferred)		Block blob	131.48 KiB	Available
CAUSE_DECES.csv	7/19/2024, 5:14:37 PM	Hot (Inferred)		Block blob	131.48 KiB	Available
COVID_DECES.csv	7/19/2024, 5:15:10 PM	Hot (Inferred)		Block blob	279.82 KiB	Available
d525b9b0-b12f-448d-837f-3a40eefca6b4	7/19/2024, 4:47:30 PM	Hot (Inferred)		Block blob	131.48 KiB	Available
da3eb5ed-1301-4850-8225-b13fda1ad45d	7/19/2024, 4:49:31 PM	Hot (Inferred)		Block blob	1 MiB	Available
HOPITAL_ADMISSION.csv	7/19/2024, 5:14:53 PM	Hot (Inferred)		Block blob	1.12 MiB	Available
reponsepays.csv	7/19/2024, 5:14:20 PM	Hot (Inferred)		Block blob	51.49 KiB	Available
TEST	7/19/2024, 4:49:29 PM	Hot (Inferred)		Block blob	102.57 KiB	Available
TEST.csv	7/19/2024, 5:14:19 PM	Hot (Inferred)		Block blob	102.57 KiB	Available

Databricks : Transformation

1. Connexion d'Azure Databricks au compte de stockage Azure

Pour établir une connexion entre Azure Databricks et un compte de stockage Azure, deux solutions couramment utilisées sont :

1. **App Registration :**
   - **Principe :** Créer une application dans Azure Active Directory (AAD) et configurer les permissions nécessaires pour accéder au compte de stockage.
   - **Configuration :** Utiliser les identifiants (ID client, ID locataire, clé secrète) dans Databricks pour l'authentification OAuth.
2. **Azure Key Vault :**
   - **Principe :** Stocker les identifiants sensibles dans Azure Key Vault pour une gestion sécurisée.
   - **Configuration :** Configurer Databricks pour accéder aux secrets dans Key Vault et les utiliser pour se connecter au compte de stockage.

En raison des limitations de notre souscription étudiante (voir annexe), nous avons directement attribué le rôle "Storage Blob Contributor" à Databricks. Sans ces limitations, nous aurions opté pour l'une de ces deux solutions car elles permettent une meilleure conformité aux pratiques de sécurité.

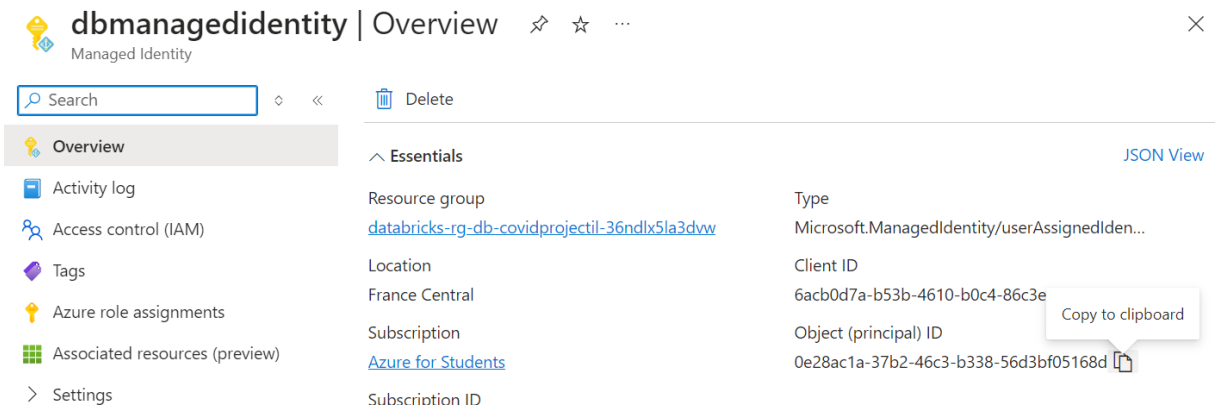


Figure 5- Copie de l'ID Managed Identity de Databricks

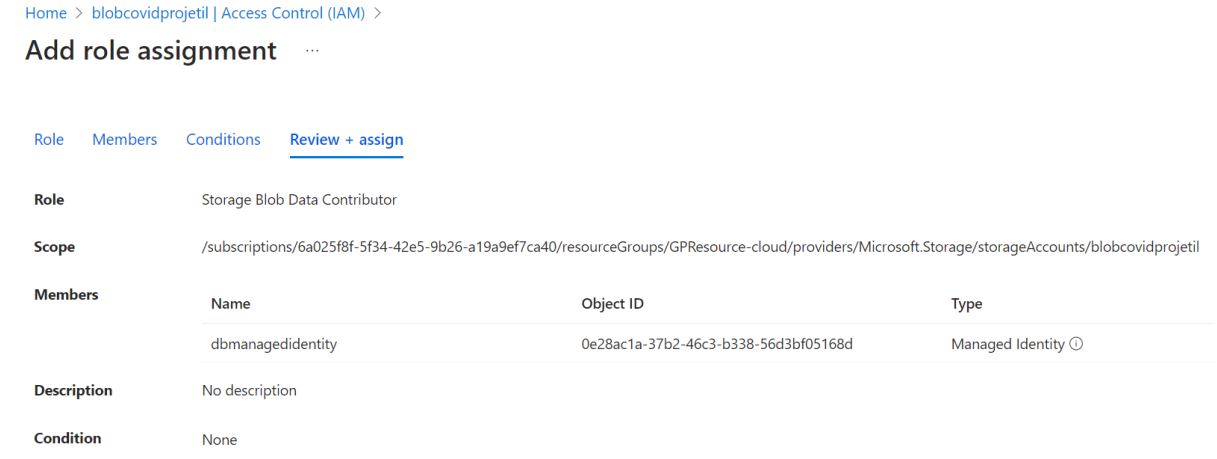
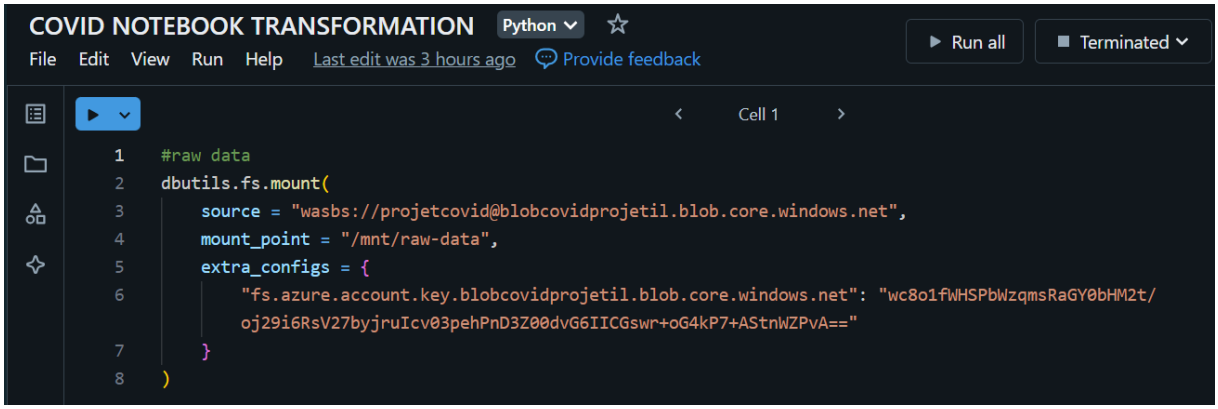


Figure 6- Ajout du rôle Storage Blob Data Contributor dans le compte de stockage

2. Transformation des données avec Spark

Une fois la connexion établie, nous avons utilisé Apache Spark dans Databricks pour effectuer des transformations sur les données stockées dans ADLS Gen2.

- **Montage des conteneurs pour les rendre accessible depuis Databricks**




```
#transformed data
dbutils.fs.mount(
    source = "wasbs://projetcovid@blobcovidprojetil.blob.core.windows.net",
    mount_point = "/mnt/transformed-data",
    extra_configs = {
        "fs.azure.account.key.blobcovidprojetil.blob.core.windows.net": "wc8o1fWHSPbWzqmsRaGY0bHM2t/
        oj29i6RsV27byjruIcv03pehPnD3Z00dvG6IICGswr+oG4kP7+AStnWZPvA=="
    }
)
```

Pour répondre aux besoins de nos analyses, nous devons préparer plusieurs tables de dimensions et de faits à partir des données brutes. Les principales transformations incluent la création de :

- Une table de dimension pour les pays extraites du fichier *cause_deces* q ui contient les informations sur les pays telles que le nom, le code, le continent ainsi que le nombre d'habitants.

- Une table de dimension pour les dates couvrant la période du 1er janvier 2020 au 30 décembre 2022 étant la période la plus critique de la pandémie.

Deux tables de faits extraites des fichiers CSV concernant les différents cas du Covid19 et les admissions hospitalières.

```
04:34 PM (<1s)                    11                    Python

hopital_admission.createOrReplaceTempView("hopital_admission")
fact_admission_hopital = spark.sql("""select country
                                        , indicator
                                        , date_format(date,'yyyyMMdd' ) AS
                                       date_key
                                        , value
                                        , source
                                        , url
                                    from hopital_admission
                                """)
```

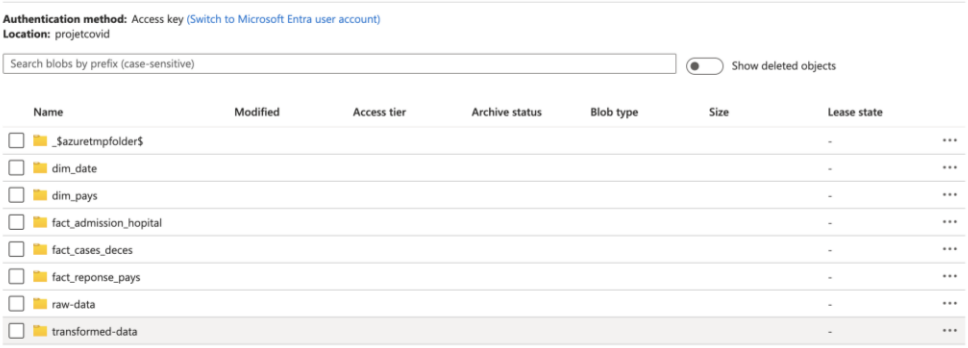
```
Just now (1s)                     10                    Python

reponse_pays.createOrReplaceTempView("reponse_pays")

fact_reponse_pays = spark.sql("""
    SELECT
        Country,
        Response_measure,
        change,
        date_format(date_start, 'yyyyMMdd') as date_start,
        date_format(date_end, 'yyyyMMdd') as date_end
    FROM reponse_pays
""")

# Display the DataFrame to verify
display(fact_reponse_pays)
```

Les tables de dimensions et de faits ont été créées et stockées dans le conteneur *projetcovid* de notre Azure Data Lake Storage. Ces tables sont désormais prêtes pour être utilisées dans nos analyses avec Power BI.



Synapse Analytics : Modélisation

Avec nos données transformées disponibles dans les tables, l'étape suivante consiste à les charger dans Azure Synapse Analytics pour la modélisation avancée.

- Configuration de l'espace de travail Azure Synapse

D'abord, nous configurons notre espace de travail Azure Synapse en créant un Synapse Studio. Cette configuration inclut également la création d'un compte de stockage Azure Data Lake Storage Gen2 (ADLS Gen2), nécessaire pour notre environnement de travail.

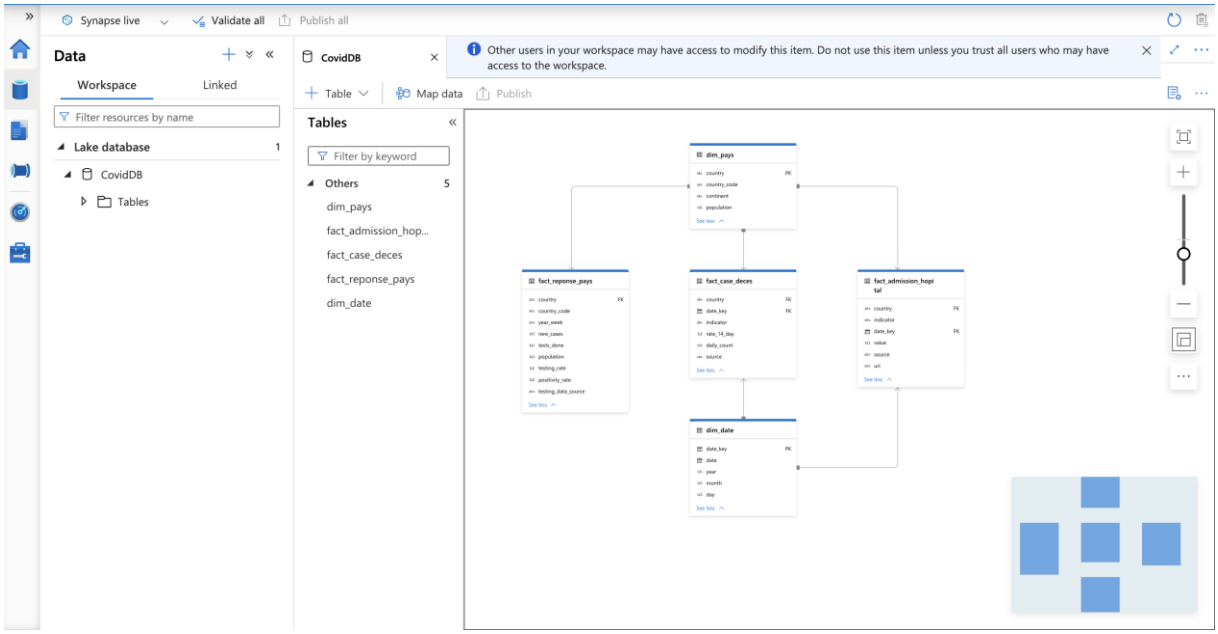
- Copie des données dans ADLS Gen2 :

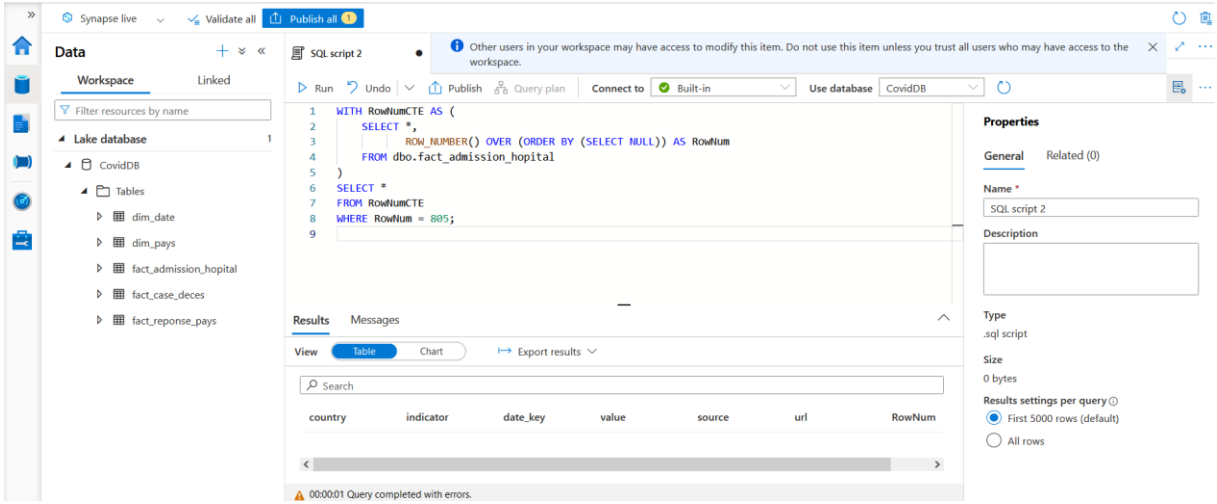
Pour utiliser Azure Synapse avec nos données, nous devons copier les fichiers du conteneur transformed-data vers notre compte de stockage ADLS Gen2. Pour cela, nous mettons en place un pipeline de copie dans Azure Synapse.

- Création et gestion des tables dans Synapse

Dans la partie "données" de notre espace de travail Synapse, nous ajoutons une base de données Lake nommée "CovidDB".

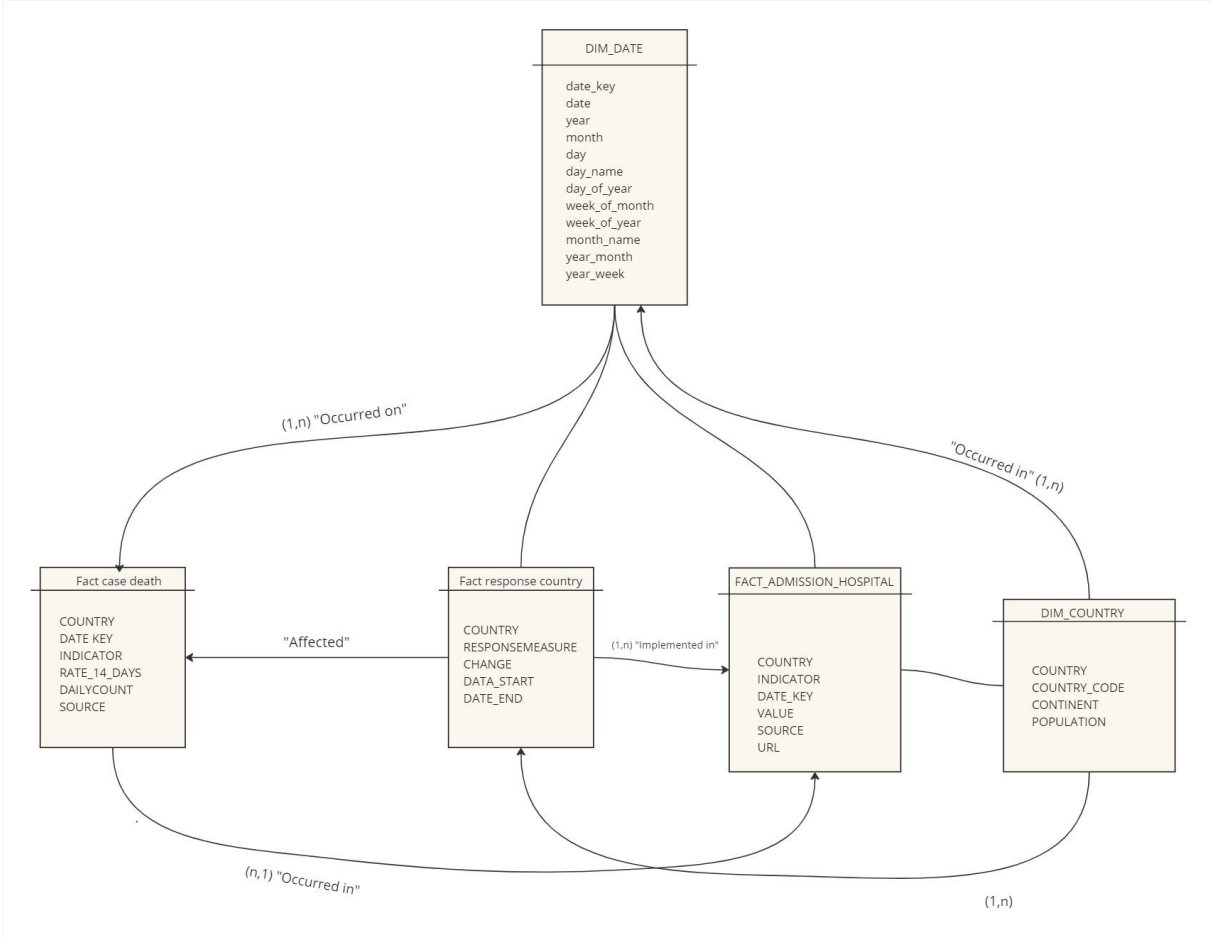
Nous créons ensuite des tables externes à partir des données présentes dans le lac de données.





Cette configuration permet à Azure Synapse Analytics de lire directement les données depuis notre Data Lake, facilitant ainsi les opérations de requêtes et d'analyses avancées. En utilisant les tables externes, nous pouvons exécuter des requêtes SQL sur les données sans avoir besoin de les déplacer, ce qui améliore l'efficacité et la performance de notre processus de modélisation.

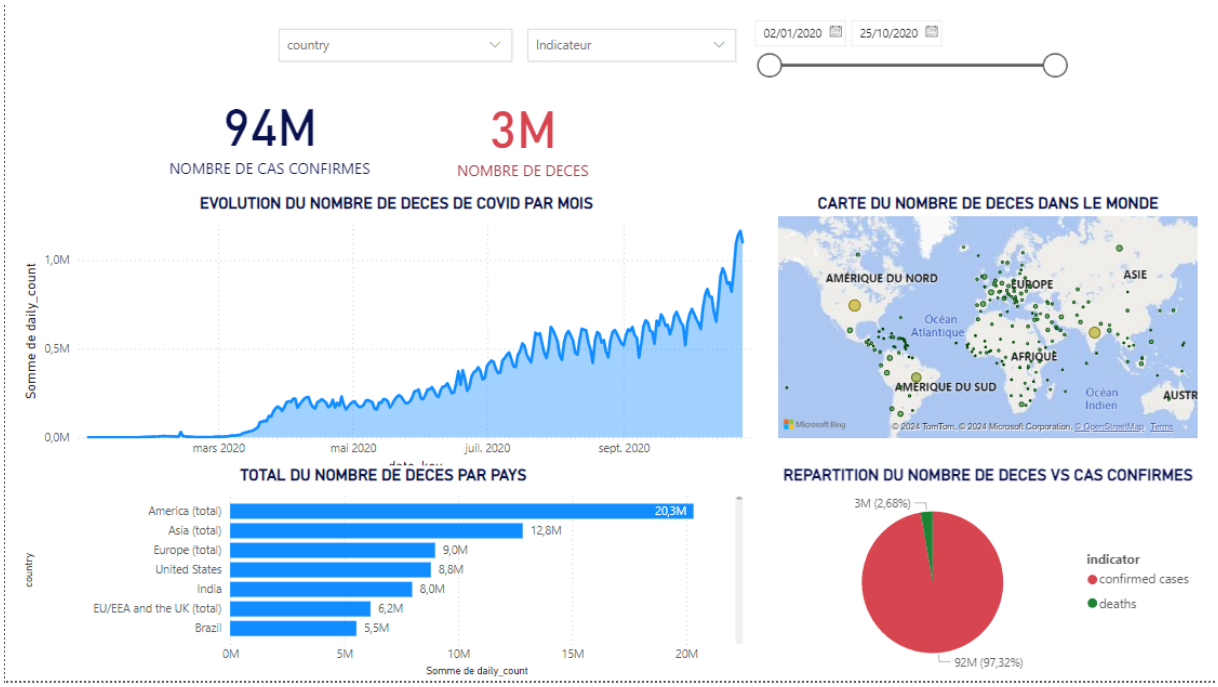
- Le modèle conceptuel de données



Le Modèle Conceptuel de Données (MCD) de ce projet décrit les relations entre différentes entités impliquées dans l'analyse des données COVID-19. Les tables principales sont DimDate et DimCountry, qui fournissent des informations temporelles et géographiques respectivement. Les tables CaseDeath, ResponseCountry, et AdmissionHospital contiennent des faits et des mesures relatives aux cas de décès, aux réponses des pays, et aux admissions à l'hôpital. Les relations entre ces tables sont établies par les clés étrangères reliant DimDate et DimCountry à chaque table de faits, permettant une analyse détaillée des données par date et par pays. Les titres des associations, tels que "Occurred on" et "Implemented in", clarifient la nature des relations entre les entités.

Les cardinalités du MCD indiquent les relations entre les entités. **DimDate** et **DimCountry** ont une relation (1,n) avec **covid_deces**, **reponse_pays**, et **hopital_admission**, signifiant qu'une date ou un pays peut être lié à plusieurs enregistrements de ces tables. **CaseDeath** et **hopital_admission** ont une relation (n,1) avec **DimDate** et **DimCountry**, chaque enregistrement de décès ou d'admission étant associé à une date et un pays spécifique. **reponse_pays** a des relations (n,1) avec les autres tables, indiquant qu'une réponse peut affecter plusieurs cas ou admissions.

PowerBI : Visualisation



Annexes

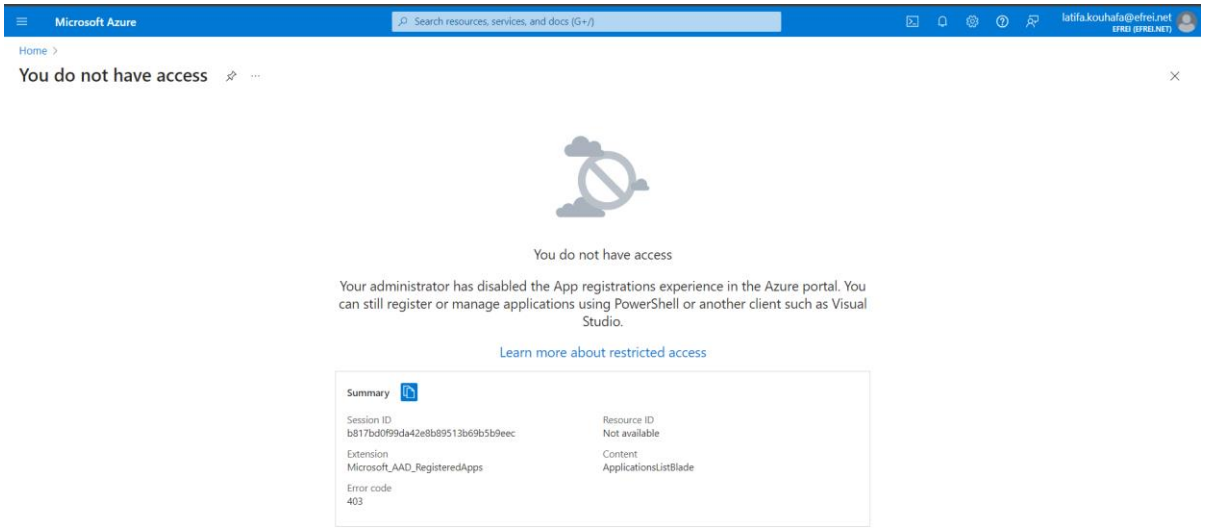


Figure 7- Section App Registration

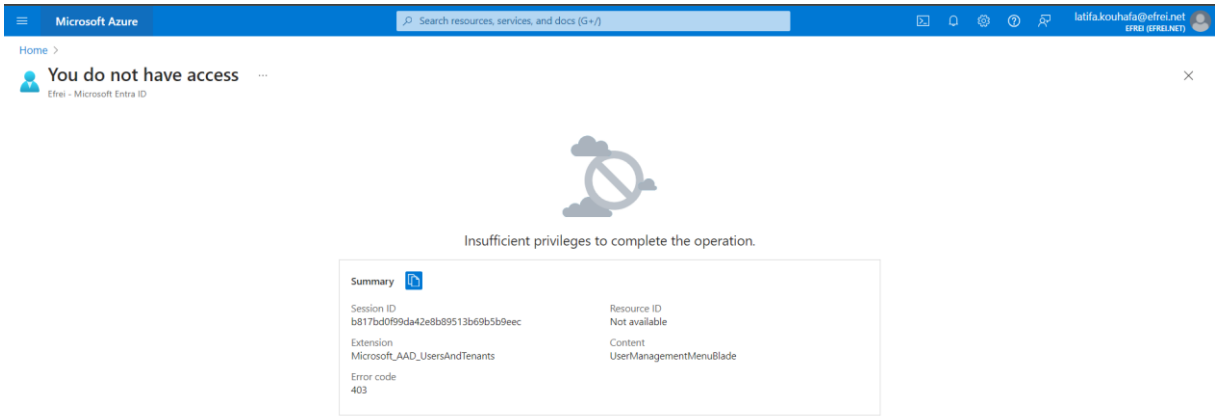


Figure 8- Section KeyVault